TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO MÔN HỌC

Cơ sở Trí tuệ Nhân tạo

PHÂN LỚP CHO BÀI TOÁN DỰ ĐOÁN BỆNH TIỂU ĐƯỜNG

GIẢNG VIÊN HƯỚNG DẪN

ThS. Đỗ Như Tài

NHÓM SINH VIÊN THỰC HIỆN

Lê Huy Hoàng	3124410104
Phạm Hữu Phú Khánh	3124410152
Nguyễn Hoài Bảo	3124560009
Nguyễn Văn Đạt	3124410062

Thành phố Hồ Chí Minh, tháng 03 năm 2026

Lời mở đầu & Mục tiêu đề tài

Phân tích bối cảnh và xác định hướng đi của nghiên cứu

Lời mở đầu

Bệnh tiểu đường đang trở thành một trong những vấn đề sức khỏe **phổ biến và nguy hiểm** nhất trên toàn thế giới.

Việc phát hiện sớm nguy cơ mắc bệnh đóng vai trò **cốt lõi** trong công tác phòng ngừa và nâng cao hiệu quả điều trị y tế.

Sự phát triển của **Học máy (Machine Learning)** mở ra khả năng dự đoán chính xác dựa trên các chỉ số y khoa thực tế.

Mục tiêu đề tài

Xây dựng mô hình

Phát triển hệ thống học máy dự đoán khả năng mắc bệnh dựa trên bộ dữ liệu Pima Indians Diabetes.

So sánh hiệu năng

Đánh giá và tìm ra mô hình tối ưu nhất giữa 3 thuật toán: Naive Bayes, KNN và SVM.

Tối ưu hóa hệ thống

Tiền xử lý dữ liệu và tinh chỉnh tham số để đạt độ chính xác cao nhất cho mô hình dự đoán.

Xác định bài toán & Dữ liệu đầu vào

TẬP DỮ LIỆU ĐẦU VÀO

File: `pima-indians-diabetes.csv`

Dữ liệu nguồn từ Viện quốc gia về bệnh tiểu đường, tiêu hóa và thận.

CÁC THUỘC TÍNH ĐẶC TRƯNG (FEATURES)

- Số lần mang thai
- Nồng độ Glucose
- Huyết áp
- Độ dày lớp da
- Lượng Insulin
- Chỉ số BMI
- Chỉ số di truyền
- Độ tuổi

MỤC TIÊU PHÂN LỚP

0 — **Negative**
Không mắc bệnh

1 — **Positive**
Có mắc bệnh

Xây dựng mô hình học máy tối ưu để dự báo chính xác hai trạng thái trên.

Tiền xử lý & Làm sạch dữ liệu

GIAI ĐOẠN 1: CHUẨN BỊ DỮ LIỆU ĐẦU VÀO

1. Phân tách tập dữ liệu

Dữ liệu được chia thành hai phần độc lập để đảm bảo tính khách quan khi đánh giá mô hình.

Train (80%)	Test (20%)
Huấn luyện	Kiểm tra

2. Xử lý giá trị bất thường

Vấn đề: Các giá trị 0 không hợp lý tại: *Glucose, BMI, BloodPressure...*

Giải pháp: Thay thế bằng giá trị **Trung bình (Mean)** hoặc **Trung vị (Median)**.

</> ĐOẠN MÃ THỰC THI TIỀN XỬ LÝ (PYTHON/SCIKIT-LEARN)

```python
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)
X_train = X_train.copy()
X_test = X_test.copy()

cols_fix = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']
for col in cols_fix:
    X_train[col] = X_train[col].replace(0, np.nan)
    X_test[col] = X_test[col].replace(0, np.nan)
    train_median = X_train[col].median()

    X_train[col] = X_train[col].fillna(train_median)
    X_test[col] = X_test[col].fillna(train_median)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```


Mục tiêu: Tăng độ tin cậy của dữ liệu đầu vào

Chuẩn hóa dữ liệu với StandardScaler

TIỀN XỬ LÝ & RÚT TRÍCH ĐẶC TRƯNG

Tại sao cần chuẩn hóa?

Các đặc trưng như **Glucose** và **BMI** có đơn vị và thang đo khác nhau. Thuật toán dựa trên khoảng cách như **KNN** và **SVM** rất nhạy cảm với sự chênh lệch này.

Cơ chế StandardScaler

- Biến đổi dữ liệu sao cho mỗi đặc trưng có **giá trị trung bình bằng 0**.
- Đưa **độ lệch chuẩn về bằng 1**.
- Loại bỏ tình trạng các đặc trưng có giá trị lớn chiếm ưu thế hoàn toàn.

IMPLEMENTATION SNIPPET

```python
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)
X_train = X_train.copy()
X_test = X_test.copy()

cols_fix = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']
for col in cols_fix:
    X_train[col] = X_train[col].replace(0, np.nan)
    X_test[col] = X_test[col].replace(0, np.nan)
    train_median = X_train[col].median()

    X_train[col] = X_train[col].fillna(train_median)
    X_test[col] = X_test[col].fillna(train_median)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

$\mu = 0$
MEAN

$\sigma = 1$
STD DEV

Giúp cải thiện đáng kể độ chính xác và tốc độ hội tụ của mô hình.

Phân tích thành phần chính (PCA)

GIẢM CHIỀU DỮ LIỆU & TRỰC QUAN HÓA KHÔNG GIAN

Trực quan hóa dữ liệu

Chuyển các đặc trưng phức tạp về hệ tọa độ 2D (PC1, PC2) để quan sát sự phân bố của nhóm bệnh nhân trên mặt phẳng.

Giảm nhiễu & Tối ưu

Loại bỏ các thành phần ít quan trọng, giữ lại những biến thiên lớn nhất của dữ liệu gốc để tăng hiệu quả tính toán.

Ranh giới quyết định

Giúp nhận diện rõ rệt ranh giới phân tách (Decision Boundary) giữa nhóm "Mắc bệnh" và "Không mắc bệnh".

"Sự phân tách của các điểm dữ liệu đại diện cho bệnh nhân trở nên rõ rệt hơn so với không gian dữ liệu gốc."

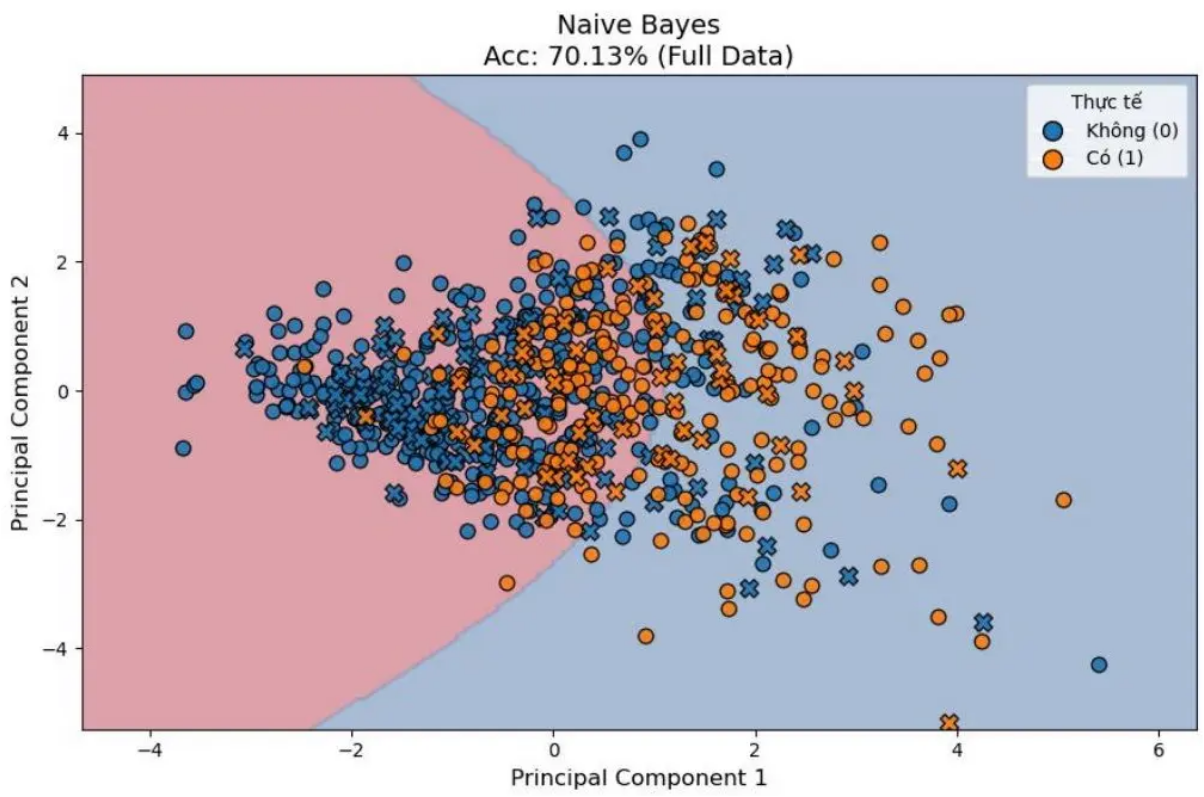

HÌNH 1. PHÂN BỐ DỮ LIỆU TRÊN KHÔNG GIAN PCA (MÔ HÌNH NAIVE BAYES)

Thành phần chính	**PC1 & PC2**
Mục tiêu	**Phân lớp 2D**

Mô hình & Quy trình thực nghiệm

MACHINE LEARNING PIPELINE

Lựa chọn mô hình

Naive Bayes

GaussianNB

Dựa trên định lý Bayes, giả định các đặc trưng độc lập. Đơn giản và huấn luyện cực nhanh.

K-Nearest Neighbors

k = 5

Phân lớp dựa trên khoảng cách tới các điểm dữ liệu lân cận nhất. Hiệu quả với dữ liệu đã chuẩn hóa.

Support Vector Machine

RBF Kernel

Sử dụng Kernel RBF để xử lý dữ liệu phi tuyến tính. Mạnh mẽ với dữ liệu nhiều đặc trưng.

Quy trình thực hiện

1. **Chuẩn bị dữ liệu**
   Sử dụng tập dữ liệu đã tiền xử lý và chuẩn hóa (X_train_scaled).
2. **Huấn luyện mô hình**
   Thực hiện model.fit() lần lượt trên 3 thuật toán đã chọn.
3. **Dự đoán & Kiểm thử**
   Dự đoán nhãn (0: Không bệnh, 1: Có bệnh) trên tập test.
4. **Đánh giá hiệu năng**
   Sử dụng chỉ số Accuracy để so sánh độ chính xác giữa các mô hình.

Kết quả thực nghiệm & So sánh mô hình

Metric: Accuracy (%)

So sánh Độ chính xác giữa các thuật toán

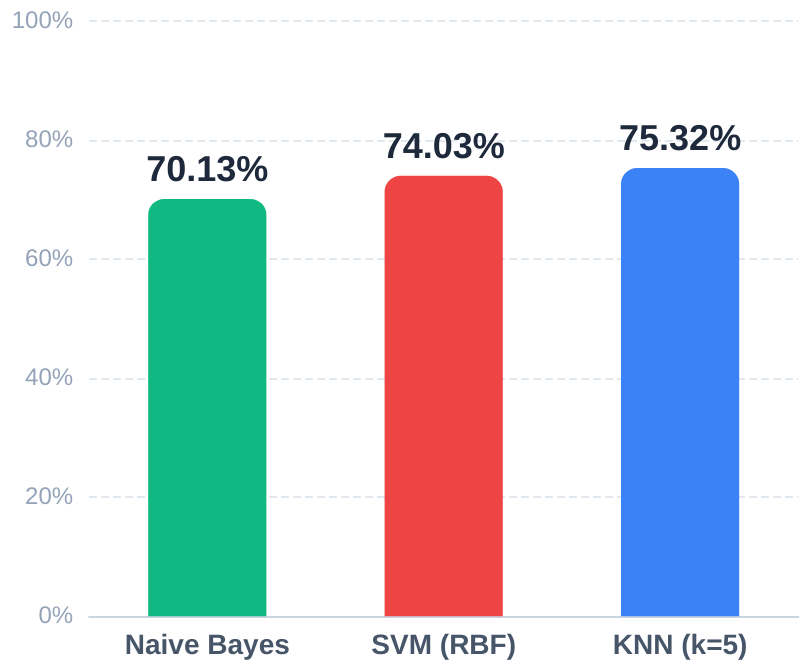

Ranh giới quyết định – KNN (k=5)

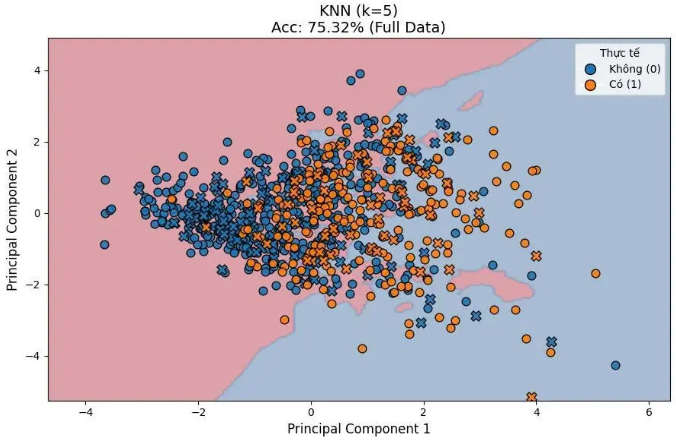

PCA 2D – Acc: 75.32% (Full Data)

MÔ HÌNH TỐT NHẤT

KNN (k=5)

Độ chính xác: **75.32%**

Phân tích kết quả

- **KNN** đạt hiệu quả cao nhất nhờ tận dụng tốt cấu trúc dữ liệu sau chuẩn hóa.
- **SVM (RBF)** bám sát với **74.03%**, xử lý tốt phi tuyến.
- **Naive Bayes** thấp nhất (70.13%) do giả định độc lập.

** Kết quả dựa trên tập dữ liệu Pima Indians Diabetes*

Clinical Validation *n=768 samples*

Tối ưu hóa tham số với GridSearchCV

Mục đích

- Nâng cao độ chính xác mô hình SVM
- Giảm Overfitting / Underfitting
- Tìm cấu hình tốt nhất tự động

Phương pháp

KỸ THUẬT
5-Fold Cross-Validation

Kernel RBF: C ∈ {0.1, 1, 10, 50}, γ ∈ {scale, auto, 0.01, 0.001}

Kernel Linear: C ∈ {0.1, 1, 10}

Kết quả tìm kiếm tối ưu

ẢNH CHỤP MÀN HÌNH KẾT QUẢ THỰC THI

```
✅ Kết quả tìm kiếm:
- Tham số tối ưu: {'C': 50, 'gamma': 0.001, 'kernel': 'rbf'}
- Độ chính xác tốt nhất (Cross-Validation): 77.69%
- Độ chính xác trên tập Test (Thực tế): 70.13%
- Độ lệch Train-Test: 7.56%
```

RANH GIỚI QUYẾT ĐỊNH – SVM (RBF KERNEL)

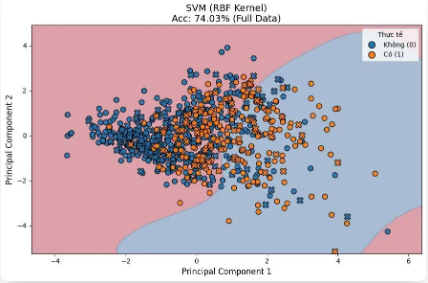

PCA 2D – Acc: 74.02% (Full Data)

THAM SỐ TỐT NHẤT	ĐỘ CHÍNH XÁC CV	ĐỘ LỆCH TRAIN-TEST
C: 50, γ: 0.001 *Kernel: RBF*	77.69%	7.56%

Mặc dù có hiện tượng **overfitting nhẹ** (độ chính xác tập Test thấp hơn Train), bộ tham số mới vẫn giúp khai thác cấu trúc dữ liệu hiệu quả hơn so với cấu hình mặc định.

Kết luận & Tài liệu tham khảo

Tổng kết đề tài

KẾT LUẬN

Mô hình hiệu quả nhất

Mô hình **KNN (k=5)** đạt độ chính xác cao nhất trong thử nghiệm ban đầu với **75.32%**.

Tối ưu hóa tham số

Việc sử dụng **GridSearchCV** giúp SVM cải thiện đáng kể trên tập huấn luyện (**77.69%**), tuy nhiên vẫn tồn tại dấu hiệu Overfitting nhẹ.

Vai trò của tiền xử lý

Chuẩn hóa *StandardScaler* và xử lý giá trị thiếu là bước then chốt giúp tăng tính ổn định và chính xác cho các thuật toán dựa trên khoảng cách.

TÀI LIỆU THAM KHẢO

[1] J. Han, M. Kamber, J. Pei, ***Data Mining: Concepts and Techniques***, 3rd Edition, Morgan Kaufmann, 2011.

[2] A. Géron, ***Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow***, O'Reilly Media, 2019.

[3] **Scikit-learn Documentation**, https://scikit-learn.org

[4] **Pima Indians Diabetes Dataset**, UCI Machine Learning Repository.

THANK YOU!